

# Detección de Clientes en Riesgo de Churn

José Antonio Flores Espinoza 37276, Elkin Alejandro Rivas Mejía 33256, Javier Antwan Rios Romero 31618

**Abstract**—Este trabajo trata la pérdida de clientes (churn) en el sector retail a partir del uso de técnicas de aprendizaje supervisado. Para ello se emplea el dataset Customer Shopping Trends, conformado por 3,900 registros y 19 variables, sobre el que se define una variable de churn a partir de la ingeniería de características que combina la frecuencia de compra y el número de compras previamente realizadas. En este trabajo se propone la formación de tres modelos de clasificación, a saber Regresión Logística, Random Forest y XGBoost, que serán evaluados a partir de las métricas ROC-AUC y matriz de confusión, así como la aplicación de los valores SHAP para la interpretabilidad de los resultados. Los resultados esperados incluyen la identificación de los factores que más contribuyen al churn, de una forma que permita las bases de análisis para la propuesta de estrategias de recuperación de clientes personalizadas.

**Index Terms**—Churn, retención de clientes, aprendizaje supervisado, clasificación binaria, Random Forest, XGBoost, Regresión Logística, SHAP, ROC-AUC, ingeniería de características, minorista, Customer Shopping Trends.

## 1 DESCRIPCIÓN DEL PROBLEMA

EN el sector minorista, la retención de clientes constituye uno de los pilares fundamentales de la rentabilidad. Diversas investigaciones han demostrado que una nueva adquisición de un cliente puede llegar a multiplicar entre cinco y veinticinco veces el coste de una retención. Sin embargo, llegar a identificar de forma anticipada qué cliente se encuentra en un estado próximo a la baja, el churn, es complicado, puesto que cada cliente exhibe sus propios patrones de conducta.

El concepto que se conoce con el nombre de churn se asocia a posibles señales, como la reducción de la frecuencia de compra, del gasto medio, la falta de interacción con promociones o la reducción de la visita a su plataforma o tienda física. Sin un sistema de alertas anticipados, las empresas no pueden tomar decisiones antes de la llegada de la pérdida.

El proyecto que se presenta se adapta a esta problemática utilizando modelos de clasificación supervisada con el dataset Customer Shopping Trends, donde no hay una variable de churn explícita, sino que se deberá generar a partir de la ingeniería de características (feature engineering).

## 2 OBJETIVOS

El objetivo principal de este proyecto es la predicción del churn (abandono de clientes) utilizando modelos de aprendizaje supervisado obtenidos del dataset Customer Shopping Trends.

### 2.1 Objetivos Específicos

- Crear una variable de churn a partir de la frecuencia de compra y el total de compras anteriores usando feature engineering.

- Crear y comparar al menos tres modelos de clasificación binaria (Logistic Regression, Random Forest, XGBoost).
- Analizar las variables del dataset que más influyen a la hora de predecir el churn a partir de los valores SHAP.
- Generar información que sirva de soporte para el diseño de estrategias de retención personalizada.
- Evaluar el funcionamiento de los modelos mediante medidas ROC-AUC, precision, recall y matriz de confusión.

## 3 MARCO TEÓRICO

### 3.1 Churn

El churn rate, o tasa de abandono de clientes, es la tasa de clientes que dejan de interactuar con una empresa a medida que transcurre el tiempo en un cierto intervalo de tiempo. Su fórmula general es:

$$\text{Churn Rate} = \frac{\text{Clientes perdidos}}{\text{Clientes al inicio del periodo}} \times 100$$

En el contexto específico de este proyecto, dado que el dataset disponible no cuenta con ningún registro de clientes que hayan decidido abandonar a la empresa de forma explícita, se construye una variable *proxy* que integra la baja frecuencia de compra (Anualmente, Cada 3 Meses, Trimestral) con un bajo historial de compras anteriores (Compras Anteriores  $\leq 13$ , percentil 25). Esta información se marca como  $\text{churn} = 1$ , mientras que el resto de los registros del dataset se consideran como  $\text{churn} = 0$ .

### 3.2 Feature Engineering

La ingeniería de características (feature engineering) es el proceso de transformar o combinar variables a partir de las variables que tenemos disponibles para conseguir nuevas

representaciones de las variables que sean capaces de aumentar la capacidad predictiva del modelo. En este trabajo la ingeniería de características se aplica para poder construir la variable objetivo de churn que se deriva de señales de comportamiento que están presentes en el dataset.

### 3.3 Modelos de Clasificación

- **Regresión Logística:** Modelo lineal para clasificación binaria que requiere primero estimar la probabilidad de pertenencia a una clase mediante la sigmoid function. Se utilizará como baseline por ser un algoritmo que se destaca en interpretabilidad y por su bajo coste computacional.
- **Random Forest:** Algoritmo ensemble que agrega varios árboles de decisión que han sido entrenados en submuestras extraídas aleatoriamente de los datos. Captura relaciones no lineales y ofrece una medida predominante de importancia de las variables.
- **XGBoost:** Algoritmo de gradient boosting que entrena árboles de decisión de forma secuencial optimizando el error residual de las iteraciones previas. Es un algoritmo que destaca por su alto rendimiento en datasets tabulares y su capacidad de regularización.

### 3.4 Métricas de Evaluación

**ROC-AUC (Receiver Operating Characteristic – Area Under the Curve).** La curva ROC representa la relación entre la tasa de verdaderos positivos (*True Positive Rate*) y la tasa de falsos positivos (*False Positive Rate*) para diferentes umbrales de decisión del modelo. El área bajo esta curva (AUC) mide la capacidad del modelo para discriminar entre las clases. Un valor cercano a 1 indica una excelente capacidad de clasificación, mientras que un valor cercano a 0.5 indica un desempeño similar al azar.

$$TPR = \frac{TP}{TP+FN} \quad FPR = \frac{FP}{FP+TN}$$

**Precision.** La precisión mide la proporción de predicciones positivas que realmente corresponden a la clase positiva. En el contexto de churn, indica qué proporción de los clientes que el modelo predice como posibles desertores realmente presentan riesgo de abandono.

$$Precision = \frac{TP}{TP+FP}$$

**Recall.** El recall, también conocido como *sensibilidad* o *True Positive Rate*, mide la capacidad del modelo para identificar correctamente los casos positivos. En este proyecto representa la proporción de clientes que realmente presentan churn y que fueron correctamente detectados por el modelo.

$$Recall = \frac{TP}{TP+FN}$$

**Matriz de Confusión.** La matriz de confusión permite analizar de forma detallada el desempeño del modelo mostrando el número de predicciones correctas e incorrectas para cada clase. Esta matriz está compuesta por cuatro elementos fundamentales:

- **Verdaderos Positivos (TP):** clientes correctamente clasificados como churn.
- **Verdaderos Negativos (TN):** clientes correctamente clasificados como no churn.
- **Falsos Positivos (FP):** clientes clasificados como churn cuando en realidad no lo son.
- **Falsos Negativos (FN):** clientes que realmente presentan churn pero que el modelo no detectó.

El análisis conjunto de estas métricas permite obtener una evaluación más completa del comportamiento de los modelos de clasificación y facilita la comparación entre las diferentes técnicas utilizadas en este trabajo.

## 4 DATASET: CUSTOMER SHOPPING TRENDS

El dataset cuenta con 3,900 registros y 19 variables que describen la conducta de compra de clientes. Las variables de mayor relevancia para este proyecto incluyen: Frequency of Purchases (7 categorías: Weekly, Bi-Weekly, Fortnightly, Monthly, Quarterly, Every 3 Months, Annually), Previous Purchases (rango: 1–50, media: 25.35), Subscription Status, Purchase Amount (USD), Discount Applied y Promo Code Used.

## 5 METODOLOGÍA

La metodología del proyecto sigue un pipeline estructurado en cinco etapas que aseguran la reproducibilidad y validez estadística de los resultados, como se expone a continuación.

- 1) **Análisis exploratorio de datos (EDA):** Se procederá a un análisis de las distribuciones de todas las variables del dataset, se evaluarán correlaciones entre ellas, se calcularán estadísticas descriptivas y se detectarán posibles outliers a partir de gráficos del tipo Boxplot. El objetivo es el de comprender el comportamiento general del dataset antes de la etapa de modelado.
- 2) **Construcción de Churn:** Dado que el *dataset* no contiene la variable *churn* de manera explícita, esta se construye a partir de las variables *Frequency of Purchases* y *Previous Purchases*. Se etiqueta como *churn* = 1 a los clientes con baja frecuencia de compra (Annual, Every 3 Months o Quarterly) y con un bajo historial de compras (*Previous Purchases* ≤ percentil 25), mientras que el resto de las observaciones se clasifican como *churn* = 0. Además, las variables categóricas se codifican mediante el método *one-hot encoding*, y las variables numéricas se normalizan para asegurar una escala comparable entre ellas.
- 3) **Base de Datos Adicionales:** Como parte del avance del proyecto, se identificaron datasets complementarios para seguir enriqueciendo el análisis de churn en retail, E-Commerce Shipping Dataset (Kaggle), que aporta variables de comportamiento posterior a la compra; Online Retail II UCI, que proporciona las transacciones reales de un e-commerce del Reino Unido (2009-2011); y Telco Customer Churn (IBM), empleado como benchmark para los modelos de clasificación de churn.

- 4) Entrenamiento y Validación de Datos: El *dataset* se dividirá en conjuntos de entrenamiento (80%) y prueba (20%), de forma estratificada respecto a la variable objetivo. En primer lugar, se entrenará un modelo de Regresión Logística como *baseline*; posteriormente, se entrenarán los modelos Random Forest y XGBoost. Todos los modelos serán evaluados mediante validación cruzada de  $k$ -pliegues ( $k = 5$ ) y utilizando las métricas descritas previamente.
- 5) Interpretabilidad con SHAP: Se calcularán los valores SHAP utilizando el modelo que tenga mejor rendimiento para identificar aquellas variables que tengan más poder explicativo de la predicción del churn a nivel global, es decir, a nivel agregado con un resumen de la importancia obtenida, y el nivel individual, que es el de la explicación por cliente.

## 6 CONCLUSIONES

En este proyecto, se presenta la propuesta de un sistema de detección de clientes en riesgo de churn en el ámbito del retail, utilizando el conjunto de datos Customer Shopping Trends y algoritmos de aprendizaje supervisado. La no existencia de una variable de churn explícita en el conjunto de datos representa el principal reto, que se solventa mediante una estrategia de ingeniería de características a partir de señales de comportamiento.

Se prevé que la comparación de tres modelos (Regresión Logística, Random Forest y XGBoost) permita determinar la arquitectura con mejor capacidad discriminativa. La introducción de los valores SHAP, aportará interpretabilidad a dicho modelo, además de facilitar la conversión de los resultados en acciones concretas tendentes a la retención de clientes, como la personalización de promociones, programas de fidelización, entre otras.

Como trabajo futuro se contempla la incorporación de otros datasets y la exploración de modelos basados en series temporales como manera de captar la evolución temporal del patrón de comportamiento del cliente.

## REFERENCES

- [1] F. Reichheld and P. Scheffer, "E-Loyalty: Your Secret Weapon on the Web," *Harvard Business Review*, vol. 78, no. 4, pp. 105–113, 2000.
- [2] Kaggle, "Customer Shopping Trends Dataset," 2023. [Online]. Available: <https://www.kaggle.com/datasets/iamsouravbanerjee/customer-shopping-trends-dataset>
- [3] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2nd ed. Sebastopol, CA: O'Reilly Media, 2019.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York: Springer, 2009.
- [5] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [6] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 785–794.
- [7] S. Lundberg and S. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.